

# 时间序列分析报告

——对近十年上证综指交易数据的分析

代一

June 21, 2017

班级： 基科 5 2

院系： 理学院物理系

学号： 2015012204

# 目录

<b>I</b>	<b>简介</b>	<b>2</b>
<b>II</b>	<b>数据分析</b>	<b>3</b>
1	数据来源及简介	3
2	初步处理	3
3	平稳性检验及差分	4
4	ARMA(p,q) Model	6
5	ARCH Model	8
5.1	建立均值方程 . . . . .	9
5.2	ARCH 效应的检验 . . . . .	10
5.3	ARCH 模型的建立 . . . . .	12
5.4	ARCH 模型的检验和预测 . . . . .	14
6	GARCH Model	18
6.1	GARCH 模型的建立 . . . . .	18
6.2	GARCH 模型的预测和检验 . . . . .	20
7	总结	22
<b>III</b>	<b>附录</b>	<b>24</b>
8	参考文献	24
9	补充说明	24

## I

# 简介

**摘要：**本文主要利用 python 的统计和时间序列分析工具，对上证综指近十年的日交易数据进行了简要分析。通过对 ARMA 模型，ARCH 模型，GARCH 模型的尝试和比较，最终选择使用 GARCH 模型对波动率进行预测。得出的结论是金融市场具有较大的波动性，同时体现出波动性聚集的特点，使用异方差模型能够对此进行较好的刻画和预测，实际使用中对交易标的的选择具有重要的意义。

**关键词：**波动率 ARMA ARCH GARCH

## II

# 数据分析

## 1 数据来源及简介

我们的数据来自于清华大学图书馆所购买的国泰安金融数据库，为上证综合指数近十年的日交易数据。开始日期为 2007-6-11，截止日期为 2017-5-23，股指代号 000001，数据包括每个交易日的开盘价，收盘价，以及涨跌幅。

上证综合指数是我国股票交易所最早发布的指数，它涵盖了上海证券交易所挂牌上市的全部的股票，是以发行量为权重的加权综合股价指数，具有较大的代表性，能够科学的表征上海证券市场乃至全国市场的波动情况。同时由于股票指数数据较易获得，数据也具有较高程度的规范性，因此我们最终选择上证综合指数作为我们分析的数据。

具体获得方法为：

- 由清华内网进入国泰安金融数据库 (<http://cn.gtadata.com/>)
- 进入数据中心-> 股票市场系列-> 市场指数
- 左侧选择交易数据-> 指数日行情文件
- 右侧依照上述内容设置相应的指数，日期和需要的数据
- 提交查询，并下载所得数据

## 2 初步处理

我们选择上证综指的每个交易日的开盘价 (Open) 进行分析，首先对其时间序列图像进行绘制，进行初步的观察的分析：



Figure.1 Open-Time

我们可以初步目测其并不平稳。同时发现图像在一些区间中存在着明显的趋势，这种趋势反映出市场行情的变化，但整体而言，每一段短时间内都没有大的波动。

### 3 平稳性检验及差分

我们选择检验平稳性的方法为 D-F 单位根检验，这是我们常用的一种平稳性检验方法，原假设  $H_0$ ：序列为非平稳的，备择假设  $H_1$ ：序列是平稳的。检验结果为：

Results of Dickey-Fuller Test:

Test Statistic	-2.377830
p-value	0.148092
#Lags Used	13.000000
Number of Observations Used	2409.000000
Critical Value (5%)	-2.862741

Critical Value (1%)	-3.433067
Critical Value (10%)	-2.567409

我们发现 p-value 较大, 同时 Test Statistic 大于 Critical Value (10%), 因此我们不能推翻原假设, 原假设成立。序列为非平稳的。

我们需要进行差分来使得序列平稳, 进行一阶差分, 得到一阶差分序列 (diff1), 其图像为:




Figure.2 diff1-Time

从图像中可以看出序列基本已经趋向平稳, 趋势已经消失。

同样进行单位根检验, 结果为:

Results of Dickey-Fuller Test:

Test Statistic	-22.553096
p-value	0.000000
#Lags Used	3.000000
Number of Observations Used	2418.000000
Critical Value (5%)	-2.862736

Critical Value (1%)	-3.433057
Critical Value (10%)	-2.567407

我们发现 p-value 极小，已经小于计算机精度，自然小于显著性水平，同时 Test Statistic 小于任何一个 Critical Value，原假设不成立，选择备择假设，即序列平稳，置信概率大于 99%。注意到检验的统计量远远小于 Criteria，这很大一部分原因是我们使用的数据较多，使得整体更加平稳。

## 4 ARMA(p,q) Model

我们首先考虑 ARMA 模型，一方面，序列已经稳定，符合 ARMA 模型稳定的要求，另一方面，ARMA 模型较为基础，也有助于其他可能模型的分析。

首先对 ACF 和 PACF 进行计算和绘制，来初步判断 ARMA 模型的阶数，图像为：




Figure.3 ACF and PACF

从图像中我们观察到，ACF 和 PACF 均没有发生拖尾，但截尾阶数较高，为了防止过拟合的情况，我们选择较为小的截尾阶数。我们发现 ACF 和 PACF 均在 4 阶处截尾。

事实上，ACF 和 PACF 在这里的表现均不算良好，性质与白噪声十分相似。

当然，为了进一步准确进行判断，我们需要 AIC 和 BIC 信息法来对模型进行选择，不妨即将  $p, q$  上限定为 4，对 AIC，结果为：

```
Out[17]:
{'aic':
  0 26779.415840 26778.297906 26773.937331 26766.416437 26754.359347
  1 26778.657218 26778.927365 26773.795437 26759.866172 26756.338218
  2 26771.826761 26772.179725 26742.724990 26744.388607 26746.336695
  3 26767.874637 26759.110787 26744.385594 26741.080688 26743.442346
  4 26752.085671 26753.681547 26746.289217 26742.922861 26744.684760,
'aic_min_order': (3, 3)}
```

Figure.4 AIC

对 BIC，结果为：

```
Out[18]:
{'bic':
  0 26791.000538 26795.674953 26797.106727 26795.378181 26789.113441
  1 26796.034265 26802.096761 26802.757181 26794.620265 26796.884661
  2 26794.996157 26801.141470 26777.479083 26784.935050 26792.675486
  3 26796.836381 26793.864881 26784.932037 26787.419480 26795.573486
  4 26786.839765 26794.227989 26792.628009 26795.054001 26802.608249,
'bic_min_order': (2, 2)}
```

Figure.5 BIC

我们发现两者的判断结果并不相同，我们最终选择 BIC 判断的结果，因为 BIC 有着较高的阶数惩罚，而 AIC 则较低，容易过估计。因此我们选择 ARMA(2,2) 模型进行拟合。

我们使用 python 中模块函数 statsmodels.tsa.arima\_models.ARMA 进行拟合，在运行过程中遇到问题：

python 报错为：

```
ValueError: The computed initial AR coefficients are not stationary
You should induce stationarity, choose a different model order, or you can
pass your own start_params.
```

经过检查和分析，发现原因有以下两点：

- diff1 时间序列的值过大，使得波动的绝对值较大，函数运行时发生错误。
- ARMA(2,2) 模型仍然不能很好的描述该序列，序列存在着较大的残差，同时可能存在着异方差使得拟合所得结果难以平稳进行。

综上，我们放弃 ARIMA 模型，该模型的拟合结果可能并不准确，也较难以拟合。我们根据 diff1 图像中也能看出波动率聚集的现象，ARCH 模型也许是更适用的。我们选择 ARCH 模型作为下一个试验模型。考虑到 diff1 的值均较大，



我们选择另一个与其性质基本等效的常用的金融量——涨跌幅 (Ratio) 作为我们的分析对象。涨跌幅实质上上也是一阶差分的结果，同时往往更受到人们的关心，更加重要。

## 5 ARCH Model

在传统计量经济学模型中，干扰项的方差被假设为常数。但是许多经济时间序列呈现出波动的集聚性，在这种情况下假设方差为常数是不恰当的。

ARCH 模型将当前一切可利用信息作为条件，并采用某种自回归形式来刻画方差的变异，对于一个时间序列而言，在不同时刻可利用的信息不同，而相应的条件方差也不同，利用 ARCH 模型，可以刻划出随时间而变异的条件方差。

我们首先刻画出涨跌幅随时间的变化：




Figure.6 Ratio-Time

波动率的集聚性从 Ratio 的图像中也较为明显，两端的波动显然较大，因此 ARCH 模型很可能适用于涨跌幅 Ratio。

ARCH 模型建立的具体步骤为：

1. 通过检验数据的序列相关性建立一个均值方程，如有必要，对收益率序列建立一个模型（如 ARMA 模型）来消除线形依赖
2. 对均值方程的残差进行 ARCH 效应检验
3. 如果具有 ARCH 效应，则建立波动率模型
4. 检验拟合的模型，并对其进行可能的改进

### 5.1 建立均值方程

建立均值方程，这里即建立一个简单的 ARMA 模型或者 ARIMA 模型。我们这里建立 AR 模型作为我们的均值方程，原因有如下几点：

- AR 模型由于其自相关的性质，使得拟合时计算量较小，较为方便；
- AR 模型作为均值方程，与 ARMA 和 ARIMA 相比并没有明显的弊端，因为 ARCH 模型的异方差中的方差的拟合可以对此进行一部分补偿和修正；
- python 中 arch 库的均值方程仅仅支持常数和 AR 模型。

类似之前的步骤，首先检验平稳性，是否需要差分。原假设  $H_0$ ：序列为非平稳的，备择假设  $H_1$ ：序列是平稳的。检验结果为：

Results of Dickey-Fuller Test:

Test Statistic	-1.164089e+01
p-value	2.148394e-21
#Lags Used	1.400000e+01
Number of Observations Used	2.408000e+03
Critical Value (5%)	-2.862741e+00
Critical Value (1%)	-3.433069e+00
Critical Value (10%)	-2.567409e+00

p-value 小于显著性水平，Test Statistic 小于 Critical Value (1%)，拒绝原假设，选择备择假设，序列是平稳的，置信程度大于 99%。

只需使用 AR 模型，因此我们绘制 PACF 图像来直接判断阶数：




Figure.7 PACF

同样的，并没有较为严格的截断阶数，我们选择较为小的 4，作为我们的截断阶数。

最终选择 AR(4) 模型作为我们的均值方程。并对其进行拟合，同样使用 `statsmodels.tsa.arima_model.ARMA` 函数进行，本次顺利拟合，结果将用于后续操作。

## 5.2 ARCH 效应的检验

我们会用混成检验 (Ljung-Box 检验) 来检验序列残差的平方的相关性，来判断是否具有 ARCH 效应。残差直接通过实际结果以及通过 AR(4) 模型计算所得结果做差得出。

残差和残差的平方图像为：




Figure.8 Residual (at) and its square

我们根据图像进一步确认了波动率聚集的现象。

对  $at^2$  序列，即残差的平方的序列进行混成检验：原假设  $H_0$ : 序列没有相关性，备择假设  $H_1$ : 序列具有相关性。我们检验 25 个自相关系数和 p-value。结果为：

Out[46]:

lag	AC	Q	P-value
1.0	0.210372	107.322182	3.783755e-25
2.0	0.230412	236.118084	5.340840e-52
3.0	0.258510	398.308946	5.145739e-86
4.0	0.243083	541.778081	6.148598e-116
5.0	0.248459	691.725516	3.022139e-147
6.0	0.156545	751.276080	5.167655e-159
7.0	0.208206	856.660497	1.093814e-180
8.0	0.190960	945.346486	9.309151e-199
9.0	0.189200	1032.441099	1.739771e-216
10.0	0.233956	1165.670269	3.654892e-244
11.0	0.161324	1229.043878	8.897359e-257
12.0	0.178410	1306.584138	1.899095e-272
13.0	0.152739	1363.439132	1.153664e-283
14.0	0.157863	1424.198051	1.002079e-295
15.0	0.194935	1516.883225	0.000000e+00
16.0	0.205126	1619.554969	0.000000e+00
17.0	0.191578	1709.150042	0.000000e+00
18.0	0.140841	1757.592689	0.000000e+00
19.0	0.227850	1884.431053	0.000000e+00
20.0	0.231556	2015.483984	0.000000e+00
21.0	0.179031	2093.857411	0.000000e+00
22.0	0.168266	2163.118215	0.000000e+00
23.0	0.111670	2193.635702	0.000000e+00
24.0	0.149153	2248.101294	0.000000e+00
25.0	0.168085	2317.299957	0.000000e+00

Figure.9 Test of Residual

p-value 小于显著性水平 0.05，我们拒绝原假设，即认为序列具有相关性。AC 也显著不为零。因此序列具有 ARCH 效应。

### 5.3 ARCH 模型的建立

在完全确定 ARCH 模型之后，我们需要确立 ARCH 模型的阶数，这可以通过残差的平方  $at^2$  序列的偏自相关函数 PACF 来确定：




Figure.10 PACF of Residual's square

这则出现了明显的拖尾现象，是预期的结果。当然，也并不是十分理想，我们发现截尾的阶数可能很大，至少在我们所列出的 lags 中，并无法十分确定截尾阶数。为了计算的简便，我们选择截尾阶数为 5。

接下来即对 ARCH(5) 模型进行拟合，均值方程为 AR(4) 模型，拟合的结果为：

#### AR - ARCH Model Results

=====					
Dep. Variable:	y	R-squared:	-0.004		
Mean Model:	AR	Adj. R-squared:	-0.006		
Vol Model:	ARCH	Log-Likelihood:	-4468.66		
Distribution:	Normal	AIC:	8959.32		
Method:	Maximum Likelihood	BIC:	9022.98		
		No. Observations:	2409		
Date:	Wed, Jun 21 2017	Df Residuals:	2398		
Time:	09:40:16	Df Model:	11		
		Mean Model			
=====					
	coef	std err	t	P> t	95.0% Conf. Int.
-----					
Const	0.0472	3.026e-02	1.560	0.119	[-1.210e-02, 0.107]
y[1]	0.0235	2.353e-02	0.998	0.318	[-2.264e-02,6.959e-02]
y[2]	-0.0478	2.753e-02	-1.737	8.233e-02	[ -0.102,6.130e-03]
y[3]	-3.2439e-03	3.142e-02	-0.103	0.918	[-6.483e-02,5.835e-02]

y[4]            -0.0315 3.306e-02    -0.952    0.341 [-9.627e-02,3.334e-02]

Volatility Model

	coef	std err	t	P> t	95.0% Conf. Int.
omega	0.9449	0.105	8.974	2.870e-19	[ 0.739, 1.151]
alpha[1]	0.0655	3.650e-02	1.795	7.267e-02	[-6.023e-03, 0.137]
alpha[2]	0.1813	4.382e-02	4.137	3.524e-05	[9.538e-02, 0.267]
alpha[3]	0.2113	5.048e-02	4.185	2.846e-05	[ 0.112, 0.310]
alpha[4]	0.1742	4.643e-02	3.752	1.754e-04	[8.321e-02, 0.265]
alpha[5]	0.1036	3.025e-02	3.424	6.163e-04	[4.429e-02, 0.163]

我们发现一些拟合的系数并不稳定，对于均值方程和波动方程，一些系数甚至并没有显著地非零，其 95% 置信区间中包含零，同时方程的 R-squared 的绝对值很小，这让我们对拟合的结果产生了一些怀疑。

经过更多的信息搜集得知，这种结果在金融数据中也是比较正常的，因为市场环境往往比较恶劣，噪声的影响较为严重，使得我们拟合时信号噪声比很低，难以准确的拟合出理想的结果。

因此我们的 ARCH 模型的最终表达式为：

$$y_t = Const + \sum_{i=1}^4 y[i] * y_{t-i} + \epsilon_t$$

$$\epsilon_t = \sigma_t * z_t, \quad z_t \sim i.i.d.(0, 1)$$

$$\sigma_t^2 = \omega + \sum_{i=1}^5 \alpha[i] * \epsilon_{t-i}^2$$

其中 y[i] 与 alpha[i] 取相应行的 coef 列对应的值。

#### 5.4 ARCH 模型的检验和预测

对于整体的拟合情况，ARCH 模型的目的往往是反映出波动性的变化，尤其是波动率的聚集情况，拟合结果因此以波动率作为表示：




Figure. 11 Result of ARCH

其中第一张图是标准化的残差，这近似是一个平稳序列，说明模型在一定程度上是正确的。第二张图为条件异方差序列。

将其与我们估计的序列的波动进行对比，为：



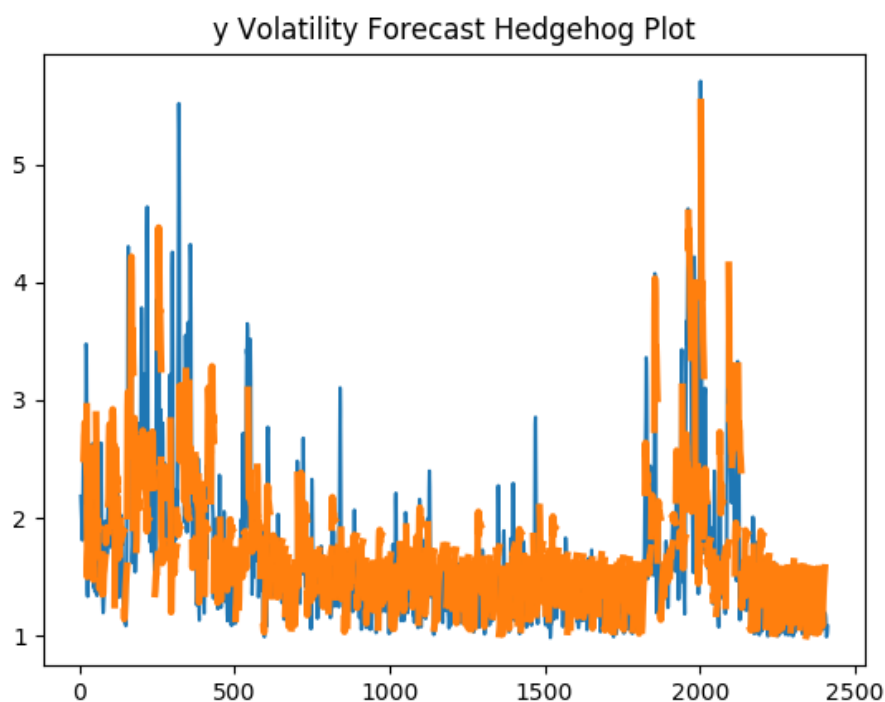


Figure. 12 Comparison of ARCH and Reality

其中橘黄色的为我们的 ARCH 模型估计的  $\sigma_t^2$ ，蓝色的为实际序列的  $\sigma_t^2$ ，我们发现两者的重合率十分之高，在末端波动较大的地方，我们的估计也很好的表现了波动率的聚集。在初始波动率较大的地方，有些估计值甚至比实际值要高，这可能是受到了后面的影响。但整体而言，对波动率的估计是较为准确的。

我们依据前面的数据，对最后十个数据进行预测（最后十个数据并未参加模型的训练），预测结果为：




Figure. 13 Forecasting of ARCH

我们发现在实际的预测中表现的差强人意，我们的预测值往往与实际值相差较大，仅根据涨跌的正负情况来看，我们只有着 60% 的正确率。主要解释为两个方面：

- 对于 ARCH 模型，其主要性质为异方差，因此模型的好坏主要取决于方差的拟合情况，仅仅通过预测值来否定一个模型是较为武断的；
- 在金融领域中，60% 预测的正确率事实上已经相当之高，因为金融市场的噪声十分大。而在长期来看，我们依据该模型进行投资，依然有着较高的收益的期望。

关键在于对波动率的预测，下面我们对最后十个波动率进行预测：

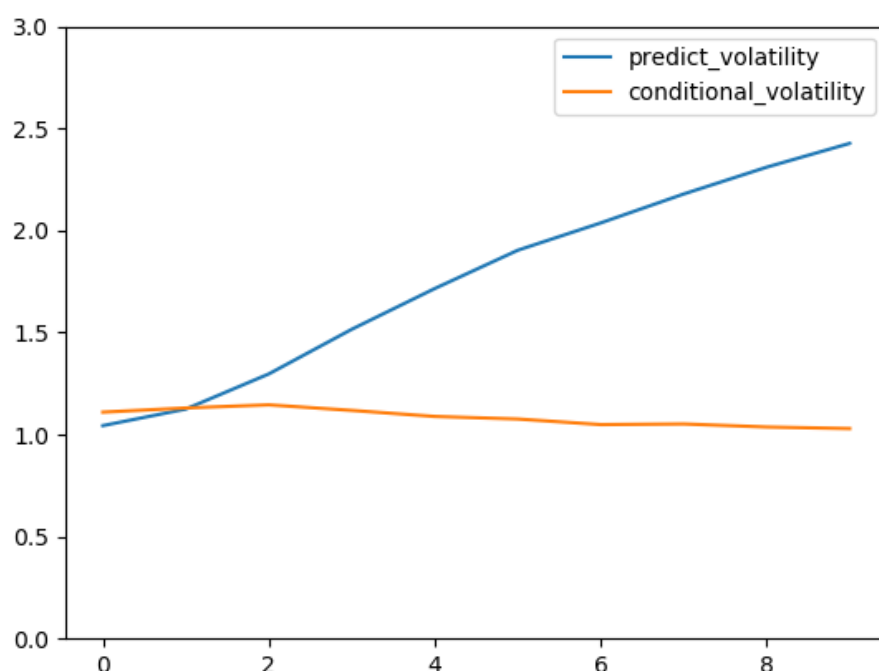


Figure. 14 Volatility Forecasting of ARCH and Reality

预测结果比实际要大许多，仅仅在量级上相同，总体上并不算太坏，可以作为参考。

综上，ARCH 模型能够不错的刻画出波动率的变化情况，同时表现出了较为明显的波动率聚集。相对于简单的 ARMA 而言，总体上来说是一种较为优秀的模型。但在预测波动率时并不能得到令人满意的结果，我们试图转向其他模型。

## 6 GARCH Model

为了更加充分的刻画收益的波动，同时更好的预测波动率的变化，我们往往需要更多的参数。此时 GARCH 模型可能更加符合我们的需求，接下来我们试使用 GARCH 模型来对序列进行浅析。

### 6.1 GARCH 模型的建立

类似于 ARCH 模型中的分析，我们使用 AR(4) 模型作为我们的均值方程，同时 ARCH 的性质既以得到检验，此处不再重复。与 ARCH 模型的建立过程也

类似, 但此时 GARCH(m,s) 模型的定阶较为困难, 人们往往使用低阶的 GARCH 模型, 如 GARCH(1,1), GARCH(1,2) 等。在金融领域, GARCH(1,1) 模型也常用于涨跌幅的拟合, 我们此处使用 GARCH(1,1) 模型。

GARCH(1,1) 模型的拟合结果为:

AR - GARCH Model Results					
=====					
Dep. Variable:	y	R-squared:	0.005		
Mean Model:	AR	Adj. R-squared:	0.003		
Vol Model:	GARCH	Log-Likelihood:	-4329.05		
Distribution:	Normal	AIC:	8674.09		
Method:	Maximum Likelihood	BIC:	8720.39		
		No. Observations:	2409		
Date:	Wed, Jun 21 2017	Df Residuals:	2401		
Time:	10:43:37	Df Model:	8		
	Mean Model				
=====					
	coef	std err	t	P> t	95.0% Conf. Int.
-----					
Const	0.0162	2.597e-02	0.622	0.534	[-3.475e-02,6.707e-02]
y[1]	0.0214	2.123e-02	1.007	0.314	[-2.024e-02,6.300e-02]
y[2]	-0.0181	2.189e-02	-0.825	0.409	[-6.097e-02,2.485e-02]
y[3]	0.0162	2.199e-02	0.738	0.461	[-2.688e-02,5.933e-02]
y[4]	0.0252	2.216e-02	1.137	0.256	[-1.824e-02,6.864e-02]
	Volatility Model				
=====					
	coef	std err	t	P> t	95.0% Conf. Int.
-----					
omega	6.3852e-03	4.515e-03	1.414	0.157	[-2.464e-03,1.523e-02]
alpha[1]	0.0494	1.022e-02	4.836	1.325e-06	[2.940e-02,6.947e-02]
beta[1]	0.9489	1.040e-02	91.281	0.000	[ 0.929, 0.969]
=====					

仅从标准差和 R-squared 来看, 拟合的结果似乎与 ARCH 在同一量级, 即并没有明显的改善。但从 beta[1] 的值来看, 我们可以发现其显著地不为 0, 即

具有较高的显著性，我们可以据此认为 GARCH 模型在此具有更多的意义，相对于 ARCH 模型，在波动率拟合的结果很可能更好。

我们得到的 GARCH(1,1) 模型表达式为：

$$y_t = Const + \sum_{i=1}^4 y[i] * y_{t-i} + \epsilon_t$$

$$\epsilon_t = \sigma_t * z_t, \quad z_t \sim i.i.d.(0, 1)$$

$$\sigma_t^2 = omega + alpha[1] * \epsilon_{t-1}^2 + beta[1] * \sigma_{t-1}^2$$

其中  $y[i]$ ,  $alpha[1]$ ,  $beta[1]$  取相应行的  $coef$  列对应的值。

## 6.2 GARCH 模型的预测和检验

对于整体的拟合情况，GARCH 模型的目的同样是反映出波动性的变化和波动率的聚集情况，拟合结果因此以波动率作为表示：




Figure. 15 Result of GARCH

图像的意义与 ARCH 对应的图像相同。

与估计序列的波动进行对比，为：

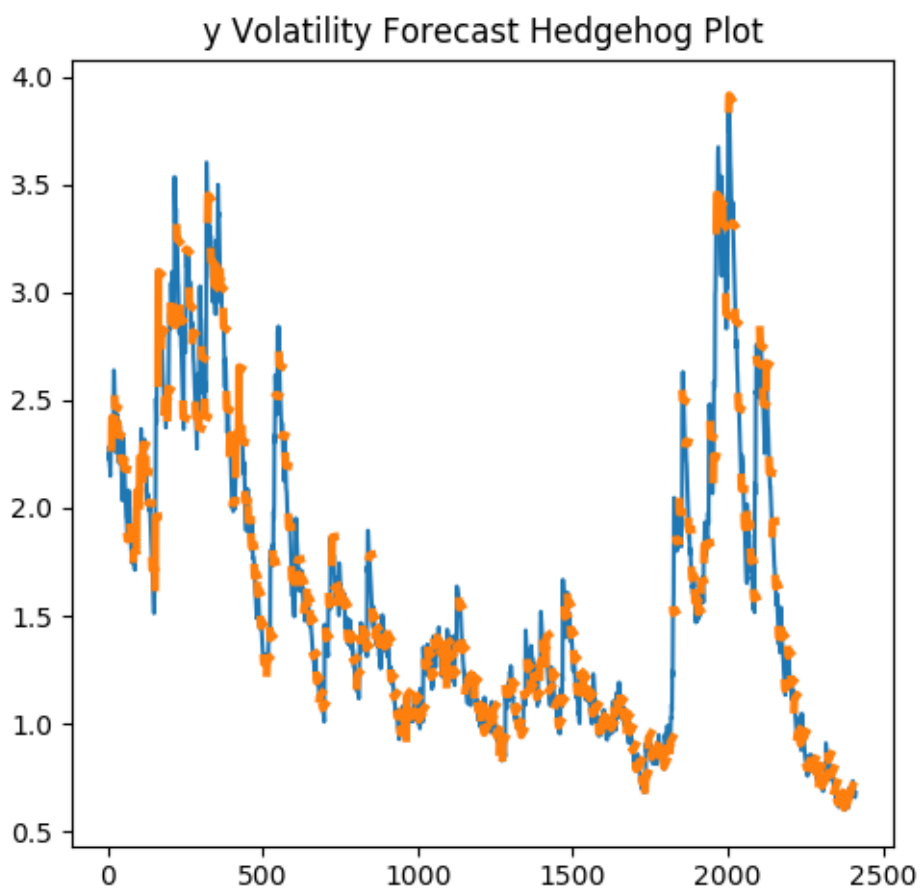


Figure. 16 Comparison of GARCH and Reality

其中橘黄色的为我们的 GARCH 模型估计的  $\sigma_t^2$ ，蓝色的为实际序列的  $\sigma_t^2$ 。我们发现基于数据可能较多的原因，一些结果暂时无法在绘图中显现。仅根据图像来看，两者的重合率相当之高，尤其是在波动率较大的地方，GARCH 模型的波动率与实际的波动率几乎相同，相对于 ARCH 模型，对波动率的预测显然更加良好。

我们不再对实际数据进行预测，仅对波动率进行预测，对最后十个波动率的预测结果结果为：




Figure. 17 Forecasting of GARCH and Reality

我们发现波动率的预测结果好的令人难以置信，当然，在拟合时较为显著的  $\beta$  某种意义上已经预示了这一点，即 GARCH(1,1) 模型对波动率的预测和估计均十分良好，相对于 ARCH 模型，在最后十个波动上的预测优秀许多。

综上，在对波动率的预测方面，GARCH 模型总体来说是最为适合的，预测结果也十分令人满意。

## 7 总结

本次实验中，我们首先使用 ARMA 模型对开盘价 Open 进行了尝试，进行了一阶差分之后稳定，但在接下来的过程中遇到了问题，转向其他模型，并分析与 diff1 类似的涨跌幅 Ratio。在使用 ARCH 模型分析的过程中，我们着重于对股指波动率的估计和预测，ARCH 模型能够较好的体现出波动率聚集的现象，但在预测时表现并不十分良好。我们最终使用 GARCH 模型，较好的表现了波动率的变化情况，同时对波动率进行了十分准确的预测。

分析的主要意义在于，对波动率的估计可以应用到各个指数，股票中去，选择波动率较大的股票，可能存在着较多的套利机会，选择波动率较小的股票，资

产的风险就能够得到限制，同时可能会收到稳健的收益。

本次的主要工作在于：

- 对不同模型进行了尝试，并进行了比较；
- 建立并检验了 ARCH 和 GARCH 模型；
- 重点放在波动率的估计和预测方面，对此进行了模型的选择和改进。

不足之处在于：

- 基于现有工具的原因，暂时并没有使用更加高级的均值方程如 ARMA 模型，仅仅使用了 AR 模型。
- 图形的绘制较为粗糙，同时一些图像显示中出现问题，给分析带来一定的不便；
- 经过对相关专业人士的咨询，发现笔者所使用的数据过多，使得不同数据之间的相互影响较大。对于股指数据，近两年的已经足够，更多年份事实上并没有太多意义，它们之间也可能并没有太多的相互关系。

对数据可以进行的后续深入分析为：

- 选取更加高级的模型对价格或者涨跌幅进行更准确的估计和预测，而不是仅仅对波动率进行预测。
- 选择一些其他序列，如其他市场的波动情况，某个行业的一些参数，作为解释变量，来使用 VAR 模型，对指数的变动进行原因的分析和预测。

最后，对老师一学期的教导和助教的辛勤工作致以诚挚的谢意！

代一

二零一七年六月



### III

## 附录

### 8 参考文献

- [1] 《金融时间序列分析》第 2 版 Ruey S.Tsay 著王辉、潘家柱译
- [2] Python Data Analysis. 2014 年十月第一版, Ivan Idris 著
- [3] Python arch 4.1 <https://pypi.python.org/pypi/arch>
- [4] Python Statesmodels <http://www.statsmodels.org/stable/index.html>

### 9 补充说明

除所引用参考文献之外, 一些函数, 程序同样参考了其他网络来源, 主要有 StackOverflow, python wiki 等。